

DOKUMENTACIJA PROJEKTA

Pametni sistem za upravljanje parking mjestima

Đorđe Zarić RA 44/2023

Dušan Kozomara RA 46/2023

Marko Pećanac RA 50/2023

Naziv predmeta: Osnove geoinformatike

Uvod i opis problema

Tema ovoga projekta je bila da se uradi aplikacija koja bi vozačima olakšavala uvid o slobodnim mjestima na parkinzima u nekim od gradova Srbije. Gradovi koji su bili pokriveni za pretragu i analizu na osnovu dostupnih podataka su Beograd, Novi Sad i Niš.

Projekat je podijeljen u tri dijela koji dijele istu PostgreSQL bazu podataka. Svaki dio može da se pokreće nezavisno, ali su međusobno povezani. Drugi dio čita parking zone unesene u prvom dijelu, a dio tri vezuje ML detekcije za iste zone putem stranog ključa.

Ideja prvog dijela je bila da se obezbijede dostupni podaci i rad sa bazom podataka. Nakon toga unijeti podaci su se dalje koristili tokom izrade projekta. Zadatak je bio da se još u prvom dijelu omogući CRUD nad tim podacima i takođe da se napravi nekoliko upita za same tabele i podatke na osnovu kojih bi se provjerila sama funkcionalnost.

Drugi dio projekta je podrazumjevaao upotrebu rasterkih podataka i geoprostornih podataka sa slojevima i rad sa njima. Bilo je potrebno učitati podatke, omogućiti uključivanje i isključivanje slojeva i promjenu simbologije i napraviti primjere nekoliko overlay tehnika (clip, union, intersection, buffer...) .

U trećem dijelu bilo je potrebno da se alatima mašinskog učenja omogući praćenje zauzetosti parkinga u realnom vremenu. Zadatak je bio da se na osnovu slike parkinga prepozna i detektuje broj zauzetih mjesta te da na osnovu odnosa kapaciteta i trenutne zauzetosti se vozači trenutno obavještavaju o stanju na parkingu.

Struktura projekta:

- **Prvi dio** - Python SQL: kreiranje seme, CRUD operacije, SQL upiti s JOIN-ovima
- **Drugi dio** - Python GEO: interaktivna Folium mapa, SHP podaci s Geofabrika, prostorne analize
- **Treći dio** - Python ML: YOLOv8 detekcija vozila, snimanje u PostGIS

Sam projekat smo radili u Python-u, gdje smo pored osnovnih funkcionalnosti dodatno koristili i dodatke datoteke za obradu geoprostornih podataka i SQL-upita. Neke od njih su pandas, geopandas, SQLAlchemy, pycogp2, scikit-learn. Pored toga koristili smo i PostgreSQL uz PostGIS. Za izradu samih korisničkih interfejsa koristili smo Streamlit.

Prvi dio

Na samom početku projekta smo se bavili kreiranjem i upravljanjem relacionom bazom podataka. Implementirali smo sedam međusobno povezanih tabela, generičke CRUD operacije, osam SQL upita sa JOIN-ovima i punjenje baze realističnim testnim podacima.

Baza sadrži sedam tabela organizovanih oko dvije centralne entitete: parking_zone i parking_spot. Svako parking mjesto ima GPS lokaciju snimljenu kao PostGIS tip GEOGRAPHY(POINT, 4326) - to je ono što omogućava prikazivanje mjesta na mapi u drugom dijelu projekta.


Tabela	Opis	Ključne kolone
parking_zone	Zona parkinga (npr. Slavija)	name, city, total_capacity, hourly_rate
parking_spot	Konkretno parking mjesto u zoni	zone_id (FK), spot_type, status, location (GEO)
driver	Registrovani vozac	first_name, last_name, email, license_number
vehicle	Vozilo vezano za vozaca	driver_id (FK), license_plate, vehicle_type
parking_session	Sesija parkiranja	spot_id (FK), vehicle_id (FK), check_in/out_time
payment	Plaćanje za sesiju	session_id (FK), amount, payment_method, status
sensor	Senzor na parking mjestu	spot_id (FK), sensor_type, battery_level

Sve tabele imaju CASCADE brisanje: brisanjem zone automatski se brisu i sva mjesta, sesije i plaćanja koja su za nju vezana. Na kraju skripte kreiraju se B-tree indeksi na stranim ključevima radi brzih JOIN upita, a za kolonu location kreira se GIST prostorni indeks.

U fajlu seed_data.py inicijalizovali smo podatke, unosili minimalno pet redova po tabeli, kao što zahtjeva zadatak. GPS koordinate parking mjesta upisuju se PostGIS funkcijom.

Nakon toga smo omogućili funkcije za sam rad nad tabelama i podacima, čitanje tabele, ubacivanje redova, unošenje novih podataka i brisanje željenih redova.


Upite nad tabelama radili smo u fajlu queries.py. Svaki upit je spajao dvije ili više tabela i demonstrira različit aspekt sistema.



Slika 1. Broj parking zona po gradovima (ukupno 24 zone)

Nakon što smo inicijalizovali zone i mjesta unesena putem seed_data.py, napravili smo tri dodatna skripte za realistično popunjavanje:

- add_zones.py - dodaje 19 novih zona (BG: 10, NS: 5, Nis: 4) s pravim adresama
- add_spots.py - dodaje parking mjesta za prvih 5 zona s GPS koordinatama
- reset_spots.py - briše sva mjesta i kreira ih iznova po kategoriji zone . Ovaj fajl dijeli zone u tri kategorije i za svaku dodaje realističan broj mjesta s nasumičnim procentom popunjenosti (20-80% slobodnih), sto rezultuje raznolikim zelenim, narandzastim i crvenim markerima na mapi



Slika 2. Prosječna velicina zone po kategoriji s rasponom vrijednosti

```

=== 1. Aktivne sesije parkiranja (vozac, vozilo, zona, mesto) ===
session_id      vozac license_plate      zona spot_number      check_in_time
      2      Ana Anic      NS789EF      Slavija      B1 2026-07-02 09:15:00
      4 Marko Markovic      BG456CD Zeleni Venac      A2 2026-07-03 07:45:00

=== 2. Broj slobodnih mesta po zoni u Beogradu ===
      zona      city slobodna_mesta
      Slavija Beograd      1
Zeleni Venac Beograd      2

=== 3. Ukupan naplaceni prihod po zoni ===
      zona prihod
Zeleni Venac 200.0
Liman 120.0
Centar 50.0

=== 4. Vozaci sa završenim sesijama iznad 100 din ===
first_name last_name session_id total_amount
Marko Markovic      1      200.0
Petar Petrovic      3      120.0

=== 5. Senzori sa niskim nivoom baterije (potrebno održavanje) ===
sensor_id spot_number      zona battery_level
      5      C2      Liman      15
      6      E1 Petrovaradin      5

=== 6. Elektricna vozila i njihove sesije ===
license_plate model spot_number status      check_in_time
BG321GH Model 3      C1 završena 2026-07-02 11:00:00

=== 7. Prosečno trajanje parkiranja po zoni (završene sesije) ===
      zona prosekno_trajanje_h
      Centar      1.0
      Liman      2.0
Zeleni Venac      2.5

=== 8. Neuspesna ili placanja na cekanju sa podacima o vozacu ===
payment_id payment_status amount first_name last_name license_plate
      6      na_cekaju 15.0      Ana      Anic      NS789EF
      5      na_cekaju 20.0      Marko Markovic      BG456CD
      4      neuspesno 30.0      Nikola Nikolic      NS987KL

```

Rezultati upita

zone_id	name	address	city	total_capacity	hourly_rate	has_covered_spots	created_at
0	1	Zeleni Venac	Zeleni venac bb	Beograd	120	80.0	True 2026-07-08 09:22:24.166028
1	2	Slavija	Bulevar kralja Aleksandra 1	Beograd	80	70.0	False 2026-07-08 09:22:24.166028
2	3	Liman	Bulevar oslobođenja 10	Novi Sad	60	60.0	True 2026-07-08 09:22:24.166028
3	4	Centar	Bulevar Nemanjica 45	Nis	50	50.0	False 2026-07-08 09:22:24.166028
4	5	Petrovaradin	Podgradje 3	Novi Sad	40	55.0	True 2026-07-08 09:22:24.166028

Tabela sa parking zonama

Drugi dio

Drugi dio projekta nam je bio streamlit web aplikacija koja vizualizuje parking sistem na interaktivnoj karti i omogućava izvršavanje raznih prostornih analiza. Podaci dolaze iz dva izvora: iz PostGIS baze relizovane u prvom dijelu i iz Shapefile fajlova preuzetih s Geofabrika.


Parking zone iz baze smo prikazivali kao jedan marker po zoni, ne kao individualna mjesta. Boja markera određuje se prema postotku slobodnih mjesta:

- **Zelena** - vise od 50% mjesta slobodno
- **Narandzasta** - izmedju 20% i 50% slobodnih
- **Crvena** - manje od 20% slobodnih mjesta


Tooltip prikazuje broj slobodnih od ukupnih mjesta, a popup sadrži informacije o cijeni po satu i da li je parking natkriven.

Overlay analyze- Ovim tehnikama prikazana je na matplotlib grafu s contextily rasterskom podlogom (CartoDB Positron). Implementirane su: buffer (zona 500 m oko parkinga), clip (isjecanje SHP sloja na parking zone), intersection (presjek parkinga i puteva), union/dissolve (spajanje svih zona u jedan objekat), difference i symmetric difference.


Upite smo implementirali geopandas operacijama nad GeoDataFrameovima: within (mjesta unutar poligona), intersects (dodirivanje s putevima), sjoin_nearest (najbliža tačka interesa po zoni), overlaps i distance.



Slika 3. Primjer popunjenosti odabranih parking zona
(crvene zone imaju manje od 20% slobodnih mjesta)



1. Buffer — zona uticaja 400 m oko parking mjesta



Treći dio

Treći dio projekta realizovan je kroz Streamlit aplikaciju koja koristi YOLOv8 model za detekciju vozila na slici parkinga. Na osnovu broja detektovanih vozila procjenjuje se broj slobodnih parking mjesta. Dobijeni rezultati se čuvaju u PostGIS bazi i mogu se pregledati i uređivati kroz četiri kartice aplikacije.

Model ne prepoznaje direktno slobodna parking mjesta. Umjesto toga, detektuje vozila, a broj slobodnih mjesta računa se kao razlika između kapaciteta parking zone i broja detektovanih vozila:

$$n_{\text{slobodnih}} = \text{kapacitet_zone} - \text{broj_detektovanih_vozila}$$

U obzir se uzimaju četiri klase vozila: **car (2)**, **motorcycle (3)**, **bus (5)** i **truck (7)**, dok se ostale klase zanemaruju. Korisnik u aplikaciji može podesiti prag pouzdanosti (confidence threshold) pomoću klizača u rasponu od 0.1 do 0.9.

Metrike modela

YOLOv8n je evaluiran na COCO val2017 skupu podataka koji sadrži 5000 slika i 80 kategorija objekata.

Precision (90.5%) pokazuje koliko su prijavljene detekcije bile tačne. Drugim riječima, od svih objekata koje je model označio kao vozila, 90.5% zaista jesu vozila. Veća preciznost znači manje lažno pozitivnih detekcija.

Recall (88.7%) pokazuje koliko je stvarnih vozila model uspio pronaći. To znači da je detektovao oko 88.7% svih vozila na slici. Kod YOLO modela ovakav odnos između preciznosti i odziva je očekivan, jer model radije propušta dio objekata nego da prijavi veliki broj pogrešnih detekcija.

F1 Score (93,8%) predstavlja kompromis između preciznosti i odziva i daje ukupnu sliku uspješnosti modela.

Svaka detekcija se čuva u tabeli ml_detection, koja se nalazi u istoj PostGIS bazi kao i ostale tabele iz prvog dijela projekta. Pored podataka o detektovanom vozilu, tabela

sadrži koordinate bounding box-a, procijenjenu GPS lokaciju, vezu sa odgovarajućom parking zonom putem stranog ključa, kao i polja za ručnu verifikaciju i napomene. Nad prostornom kolonom kreiran je GIST indeks radi bržeg izvršavanja prostornih upita.

Streamlit aplikacija je podijeljena u četiri kartice:


Tab 1 – Detekcija

Korisnik učitava sliku parkinga, bira parking zonu i podešava prag pouzdanosti modela. Nakon obrade prikazuje se broj zauzetih i slobodnih mjesta, procenat popunjenosti i status parkinga.

Boja statusa zavisi od broja slobodnih mjesta:

- crvena – manje od 15% slobodnih mjesta,
- narandžasta – između 15% i 50%,
- zelena – više od 50%.

Prikazuje se i anotirana slika sa označenim vozilima, kao i Folium mapa sa lokacijom parking zone.



The screenshot shows the 'Parking zona' section with a dropdown menu set to 'Liman 3 - Novi Sad'. Below it is a text input for 'Ukupan kapacitet zone (mjesta)' set to '50'. A slider for 'Min. pouzdanost detekcije' is set to '0.25'. Under 'Fotografija parkinga', there is a file upload button and a preview of a file named 'paromli...24x669.jpg' (144.5KB). A large image of a parking lot is displayed on the right, labeled 'Originalna slika'. At the bottom, there is a red button '▶ Analiziraj slobodna mjesta'. Below the button, three statistics are shown: 'Zauzeta mjesta' (25), 'Slobodna mjesta' (25), and 'Popunjenost' (50%).

Zauzeta mjesta	Slobodna mjesta	Popunjenost
25	25	50%

Tab 2 – Uređivanje atributa

Omogućava izmjenu sačuvanih detekcija. Moguće je promijeniti status, klasu vozila, napomenu i oznaku verifikacije, kao i obrisati pojedinačne zapise.

Uređivanje atributa detekcija

Odaberite detekciju


ID 1 – zauzeto | car

Status: zauzeto

Klasa vozila: car

Napomena

☐ Verifikovano



Tab 3 – Pregled podataka

Prikazuje tabelarni pregled svih detekcija uz mogućnost filtriranja po statusu. Pored toga, prikazuju se osnovne statistike i mapa svih parking zona sa bojama koje odgovaraju posljednjim rezultatima detekcije.

Pametni parking – detekcija slobodnih mjesta (Deo 3)

Detekcija Uređivanje atributa **Pregled podataka** Prostorne analize

Pregled svih detekcija

Status: ☐ Samo verifikovane

Prikazano 60 od 60 zapisa

	ID	Izvor	Vreme	Status	Pouzdanost	Vozilo	Lon	Lat	zone_ref	Napomena	Verifikovano
0	1	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.8946	car	19.8227	45.2396	3		☐
1	2	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.8903	car	19.823	45.2398	3		☐
2	3	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.8867	car	19.8215	45.2406	3		☐
3	4	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.8619	car	19.8215	45.2408	3		☐
4	5	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.8485	car	19.8216	45.2409	3		☐
5	6	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.845	car	19.8219	45.2408	3		☐
6	7	paromlin_parking5-011012-1024x669.jpg	2026-07-08 08:15:43	zauzeto	0.7908	car	19.8218	45.2406	3		☐

Tab 4 – Prostorne analize

Posljednja kartica prikazuje nekoliko prostornih analiza nad sačuvanim detekcijama. Obuhvata buffer od 30 m oko slobodnih mjesta uz Contextily podlogu, pie chart zauzetih i slobodnih mjesta, DBSCAN klasterovanje detekcija prema geografskoj blizini, poređenje

ML detekcija sa parking mjestima iz baze i sjoin_nearest analizu koja za svaku detekciju pronalazi najbliže parking mjesto iz baze podataka.

P Pametni parking – detekcija slobodnih mjesta (Deo 3)

Detekcija Uređivanje atributa Pregled podataka **Prostorne analize**

Prostorne analize

> 1. Buffer zona (30 m) oko slobodnih mjesta

> 2. Udio slobodnih vs. zauzetih mjesta

> 3. DBSCAN klasterovanje mjesta

> 4. ML slobodna mjesta vs. DB parking mjesta

Moguća unapređenja modela

Distance/nearest-neighbor upiti (ST_DWithin, sjoin_nearest) su u projektu implementirani prvenstveno kao demonstracija mogućnosti PostGIS-a i GeoPandas-a. U realnom sistemu bi ovakav upit bio osnova za jednu od najvažnijih funkcija za korisnika: predlaganje vozaču najbližeg slobodnog mjesta u odnosu na njegovu trenutnu GPS lokaciju.

Spatial join operacije bi se mogle iskoristiti za automatsko mapiranje parking zona na šire prostorne cjeline (opštine, zone naplate, saobraćajne sektore), kao i za automatsko povezivanje senzora ili ML detekcija sa najbližom parking zonom, bez potrebe za ručnim unosom stranog ključa.

Integracija sa stvarnim IoT senzorima zauzetosti, umjesto povremenog fotografisanja, omogućila bi ažuriranje stanja parkinga u realnom vremenu.

Fino podešavanje (fine-tuning) YOLO modela na skupu slika snimljenih iz stvarnih uglova nadzornih kamera poboljšalo bi tačnost detekcije i omogućilo pouzdanije određivanje GPS koordinata slobodnih mjesta.

Uvođenje predikcije zauzetosti na osnovu istorijskih podataka (npr. po danu u nedjelji i dobu dana) omogućilo bi vozačima planiranje dolaska unaprijed.

Zaključak

Implementirali smo funkcionalan prototip sistema za pametno upravljanje parking mjestima

koji pokazuje kako se različite tehnologije mogu povezati u jednu funkcionalnu aplikaciju. Kombinacijom relacione baze podataka sa PostGIS prostornim tipovima, interaktivne GIS vizualizacije i ML detekcije razvijen je sistem koji bi, uz pristup stvarnim senzorskim podacima, mogao predstavljati dobru osnovu za primjenu u realnim uslovima.

Glavno ograničenje trenutne implementacije odnosi se na GPS koordinate slobodnih parking mjesta. Naime, one nisu stvarne koordinate konkretnih mjesta, jer ih nije moguće pouzdano odrediti na osnovu samo jedne slike kamere. Pored toga, korišteni YOLOv8n model treniran je na COCO skupu podataka, koji nije specijalizovan za prepoznavanje automobila iz ptičije perspektive.

Iako postoje navedena ograničenja, razvijeni prototip uspješno demonstrira ključne koncepte obrađene u okviru predmeta. Kroz jedinstvenu aplikaciju prikazana je primjena prostornih tipova podataka, koordinatnih sistema, GIS slojeva, overlay analiza, prostornih upita i mašinskog učenja, čime je odgovoreno na osnovne zadatke ovoga projekta.